

Predicción de precios y clasificación de sistemas constructivos en el mercado inmobiliario de Tokio mediante aprendizaje automático

Franco Bournissent, Camilo Jiménez, Manuel Lafosse

Inteligencia Artificial y Aprendizaje Automático I, Licenciatura en Ciencia de Datos, Facultad de Química e Ingeniería, Pontificia
Universidad Católica Argentina (UCA), Rosario, Argentina

Resumen — El mercado inmobiliario de Tokio presenta una heterogeneidad extrema: conviven operaciones residenciales de pocos millones de yenes con transacciones corporativas que superan los ¥170.000 millones. Este trabajo aborda dos tareas complementarias sobre el registro público de transacciones del Ministerio de Tierra, Infraestructura, Transporte y Turismo (MLIT) de Japón: estimar el valor de transacción y clasificar el sistema constructivo del edificio. Se procesaron 343.995 operaciones de la Prefectura de Tokio (2005–2025) resolviendo cinco problemas de calidad no triviales, entre ellos un artefacto de codificación en las superficies, valores textuales en la distancia a estación y un objetivo de clasificación multi-etiqueta. Para la regresión se compararon tres modelos sobre el logaritmo del precio: XGBoost obtuvo el mejor desempeño ($R^2 = 0,848$ en escala logarítmica; $R^2 = 0,267$ en yenes). Para la clasificación, con un desbalance de 65,6:1, XGBoost alcanzó un F1 macro de 0,568, un coeficiente kappa de 0,636 y una exactitud de 0,892, mientras que la regresión logística —el mejor clasificador individual— alcanzó un ROC-AUC one-vs-rest de 0,903. Se identificó una relación contraintuitiva: la distancia a la estación correlaciona débilmente con el precio ($r = -0,07$) pero de manera apreciable con los índices de edificabilidad. Un análisis no supervisado mediante k-medias sobre el conjunto completo de variables mostró una correspondencia parcial con las clases reales (ARI = 0,211). Ambos modelos se desplegaron en una aplicación web pública que comunica explícitamente la incertidumbre de sus estimaciones.

Palabras clave: *aprendizaje automático, mercado inmobiliario, regresión, clasificación multiclase, desbalance de clases, despliegue de modelos.*

1. Introducción

La valuación inmobiliaria automatizada (Automated Valuation Model, AVM) constituye una de las aplicaciones más consolidadas del aprendizaje automático sobre datos tabulares. Su utilidad abarca desde la tasación asistida hasta el análisis de política urbana, y su viabilidad depende críticamente de la disponibilidad de registros de transacciones suficientemente extensos y confiables. El caso japonés resulta particularmente interesante: el MLIT publica de forma abierta los precios de transacción reportados por las partes intervinientes, con un nivel de detalle que incluye atributos del lote, del edificio y del entorno urbano [1].

La Prefectura de Tokio presenta, sin embargo, una dificultad estructural. Su mercado es extraordinariamente heterogéneo: los distritos centrales concentran edificios corporativos cuyo valor supera en varios órdenes de magnitud al de las viviendas unifamiliares de los distritos periféricos. Esa heterogeneidad, sumada a las imperfecciones propias de un registro autoreportado, convierte al conjunto de datos en un caso de estudio exigente tanto para la preparación de datos como para el modelado.

Trabajos previos sobre predicción de precios inmobiliarios han mostrado que los métodos de ensamble basados en árboles superan consistentemente a los modelos lineales en datos tabulares heterogéneos [2], [3]. La transformación logarítmica del objetivo es práctica habitual ante distribuciones de precios con asimetría severa [4]. Por su parte, la clasificación bajo desbalance de clases exige métricas específicas: la exactitud resulta engañosa cuando una clase domina la muestra, y se recomienda el uso de F1 macro o del coeficiente kappa [5].

Este trabajo persigue tres objetivos:

- OE1 — Caracterizar y resolver los problemas de calidad del registro del MLIT para la Prefectura de Tokio, documentando cada decisión metodológica.
- OE2 — Comparar tres algoritmos de regresión para estimar el valor de transacción y cinco algoritmos de clasificación (tres individuales y dos de ensamble) para predecir el sistema constructivo del edificio.
- OE3 — Desplegar los modelos resultantes en una aplicación web accesible públicamente, que comunique de manera responsable la incertidumbre de sus predicciones.

Organización del documento: el presente trabajo se organiza de la siguiente forma. En la sección 2 se describe la metodología, abarcando el conjunto de datos, el preprocesamiento (TP1), los algoritmos de predicción (TP2) y clasificación (TP3), y la estrategia de despliegue (TP4). La sección 3 presenta los resultados del análisis exploratorio y de ambas familias de modelos, junto con la aplicación desplegada. La sección 4 discute críticamente esos resultados y las decisiones metodológicas adoptadas. La sección 5 sintetiza las conclusiones y las líneas de trabajo futuro.

2. Metodología

2.1 Conjunto de datos

El conjunto de datos comprende 343.995 transacciones de la Prefectura de Tokio registradas entre 2005 y 2025, descritas por 27 variables originales. Cada fila corresponde a una operación de compraventa reportada al MLIT. El archivo se distribuye con codificación Windows-1252, aspecto que resultó relevante para el preprocesamiento.

Una decisión de diseño temprana fue trabajar sobre la prefectura completa en lugar de acotarse a un único distrito. Esto habilita el uso del ward (distrito administrativo) como variable predictora, incorporando 59 categorías geográficas que, como muestra la sección 3, resultan determinantes para el precio. El conjunto se divide en dos naturalezas según la variable Type: operaciones de terreno con edificio (68,3%) y de solo terreno (31,7%), distinción que explica la mayor parte de los valores faltantes.

2.2 Preprocesamiento y problemas de calidad (TP1)

El preprocesamiento debió resolver cinco problemas no triviales, cuya identificación constituye en sí misma un aporte del trabajo.

Artefacto de codificación. Las columnas de superficie llegan con el carácter japonés correspondiente a metro cuadrado corrompido en una secuencia espuria de dos caracteres ASCII. Los valores del extremo superior aparecen como una etiqueta textual que indica «2.000 o más». Una conversión numérica directa los habría transformado en nulos, eliminando precisamente las operaciones de mayor superficie: 1.691 en la superficie de terreno y 1.621 en la superficie construida. Se extrajo el valor mediante expresiones regulares y se marcó la censura con una variable indicadora.

Distancia a estación no numérica. La variable combina minutos numéricos con rangos textuales («30-60minutes», «1H-1H30», «2H-»). Se implementó un analizador que convierte cada formato a minutos, tomando el punto medio en los intervalos cerrados y el extremo inferior en los abiertos. La conversión resultó completa: no quedaron valores sin interpretar (media resultante de 12,99 minutos, mediana de 10).

Nulos estructurales. Las operaciones de tipo Land Only carecen de edificio por definición: superficie construida, año de construcción y estructura están vacíos por naturaleza del registro, no por ausencia de dato. Imputar estadísticamente esas columnas habría fabricado edificios inexistentes. Se optó por un indicador binario (sin_edificio) y relleno neutro, tratando por separado cada naturaleza.

Inconsistencias temporales. Se detectaron 7.066 registros con antigüedad negativa, es decir, edificios cuyo año de construcción es posterior al de la operación. A diferencia de los casos anteriores, se trata de errores genuinos de carga: se marcaron con una variable indicadora (antigüedad_inconsistente) y se llevaron a cero.

Objetivo multi-etiqueta. La variable Building : Structure no presenta cuatro categorías limpias sino 26, incluyendo combinaciones («RC, W») y clases marginales (LS, B). Se derivó la variable estructura_principal conservando el primer sistema constructivo listado y agrupando las categorías marginales bajo «Otros». El 0,46% de los registros presentaba etiquetas múltiples.

2.3 Ingeniería de características

Se derivaron variables temporales (año y trimestre de operación, antigüedad del edificio), de densidad (ratio construido, cociente entre superficie construida y del terreno) y seis indicadores binarios de uso a partir de la columna multi-valor Use. Se incorporó además el precio por metro cuadrado, utilizado en el análisis exploratorio y como predictor en la tarea de clasificación, pero excluido de la regresión por constituir fuga directa del objetivo.

El tratamiento de la cardinalidad geográfica mereció atención específica. El ward (59 categorías) se codificó mediante one-hot, por ser interpretable y de cardinalidad manejable. En cambio District (1.449 categorías) y la estación más cercana (663) se redujeron a las 100 categorías más frecuentes de cada una (101 tras agrupar el resto), agrupando el resto bajo «Otros», para luego aplicar codificación por frecuencia. Un criterio inicial basado en umbral porcentual (0,5%) resultó inadecuado: con 344.000 filas exigía más de 1.700 casos por categoría, relegando cerca del 75% de los distritos y el 54% de las estaciones a la categoría residual. El criterio top-N controla el número de categorías con independencia del tamaño de la muestra. Tras la codificación, el conjunto alcanza 160 columnas.

2.4 Diseño experimental y algoritmos

Ambas tareas emplean partición hold-out 80/20 con semilla fija y validación cruzada de cinco particiones sobre el conjunto de entrenamiento. Todo el preprocesamiento se encapsuló en objetos Pipeline de scikit-learn [6], de modo que la imputación y el escalado se ajustan exclusivamente sobre los datos de entrenamiento en cada partición, evitando fuga de información.

Para la regresión (TP2), el objetivo Total transaction value se modela como $\log(1+y)$ y las métricas se reportan tanto en escala logarítmica como en yenes aplicando la transformación inversa. Se compararon Regresión Lineal Múltiple como línea de base, Random Forest y XGBoost [2]. Las métricas empleadas son RMSE, MAE, R^2 , R^2 ajustado y MAPE. Como referencia trivial, un predictor que siempre estima la mediana del precio obtiene $R^2 \approx -0,005$ en yenes, cota mínima que todo modelo debe superar.

Para la clasificación (TP3) se aplicó partición estratificada y el parámetro class_weight balanceado en los modelos que lo admiten. El trabajo distingue dos bloques de modelos: una Sección B de clasificadores individuales — Regresión Logística multinomial, Árbol de Decisión y Naive Bayes, elegidos por diversidad de sesgo inductivo— y una Sección D.2 de métodos de ensamble —Random Forest (bagging) y XGBoost (boosting)—, incorporados posteriormente al mismo registro de resultados para poder aislar el efecto de cada estrategia de ensamble frente a su modelo base. XGBoost no admite class_weight en problemas multiclase, por lo que su desbalance se gestiona a través de las métricas macro y el análisis por clase. La métrica de referencia es el F1 macro, complementada con matrices de confusión normalizadas por fila, coeficiente kappa de Cohen y ROC-AUC one-vs-rest —esta última calculada sobre los tres clasificadores de la Sección B—. Se descartaron del conjunto de predictores las variables que quedan constantes al filtrar a operaciones con edificio (sin_edificio y Type), ya que una variable sin varianza no aporta información y sólo agrega ruido dimensional.

Se incorporó además un análisis no supervisado mediante k-medias (MiniBatchKMeans, por su mayor velocidad frente a K-Means clásico con más de 200.000 filas), con un número de clusters igual al número de clases, ejecutado sobre la totalidad de las features que reciben los clasificadores —incluyendo precio, ward y la geografía codificada—, contrastado con las clases reales a través del índice de Rand ajustado (ARI). Los dos primeros componentes de un PCA sobre el mismo espacio se usan únicamente para visualizar la separación entre clusters y clases.

2.5 Estrategia de despliegue (TP4)

Los modelos ganadores de cada tarea se serializaron con joblib como objetos Pipeline completos, incluyendo imputadores, escaladores y codificadores. Esta decisión es central para la reproducibilidad: la aplicación no replica lógica de preprocesamiento alguna, sino que recibe los datos del formulario en su forma cruda y delega todas las transformaciones en el pipeline serializado.

La aplicación se desarrolló con Streamlit [7] y se desplegó en Streamlit Community Cloud, conectada a un repositorio público de GitHub. Se organiza en tres pestañas: estimación de precio, clasificación de estructura e información sobre los modelos y sus limitaciones. La validación de entradas se implementa mediante widgets con rangos acotados (sliders y campos numéricos con mínimos y máximos), y desplegables poblados con las categorías reales observadas en el entrenamiento, de modo que resulta imposible ingresar un valor fuera del dominio del modelo.

3. Resultados

3.1 Análisis exploratorio de datos

La distribución de valores faltantes, presentada en la Fig. 1, confirma el patrón estructural anticipado: las columnas asociadas al edificio concentran alrededor del 35% de nulos, proporción que coincide con el peso de las operaciones de solo terreno. La columna Land : Price per m2 exhibe el comportamiento inverso, con 68,3% de faltantes, ya que solo se reporta en operaciones sin construcción.




Fig. 1: Proporción de valores faltantes por columna en el conjunto completo.

La distribución del precio presenta una asimetría extrema, con un coeficiente de 150,4, mediana de ¥46 millones, media de ¥96,5 millones y máximo de ¥170.000 millones. La transformación logarítmica reduce la asimetría a 0,38, justificando su adopción como escala de modelado. La Fig. 2 muestra el contraste entre ambas escalas junto con las restantes variables numéricas.




Fig. 2: Distribución de las principales variables numéricas. El panel superior central muestra el efecto de la transformación logarítmica sobre la asimetría del precio.

El hallazgo más relevante del análisis exploratorio proviene de la comparación entre distritos, presentada en la Fig. 3. El precio mediano por metro cuadrado varía en un factor cercano a cuatro: Chiyoda alcanza ¥2,4 millones/m² mientras que los distritos del extremo inferior del ranking se sitúan en torno a ¥0,63 millones/m². Más aún, el ordenamiento por volumen de operaciones resulta prácticamente inverso: Setagaya, Nerima y Adachi lideran en cantidad de transacciones sin figurar entre los distritos más caros, mientras que Chiyoda es el más costoso con apenas 1.548 operaciones registradas. Esta disociación entre precio y volumen justifica empíricamente la incorporación del ward como predictor y valida la decisión de trabajar sobre la prefectura completa.




Fig. 3: Comparación entre distritos: precio mediano por m² (izquierda) y volumen de operaciones (derecha). Los ordenamientos son prácticamente inversos.

Un segundo hallazgo resulta contraintuitivo. Como se observa en la matriz de correlación de la Fig. 4, la distancia a la estación ferroviaria muestra una asociación muy débil con el precio ($r = -0,07$), contra la expectativa de que la accesibilidad fuera un determinante principal. Sin embargo, correlaciona apreciablemente con los índices de edificabilidad: $-0,36$ con el building coverage ratio y $-0,33$ con el floor area ratio. La interpretación plausible es que la proximidad a estaciones opera principalmente a través de la zonificación urbana —las áreas mejor conectadas admiten mayor densidad constructiva— y que su efecto sobre el precio es por tanto indirecto. Se detectó además colinealidad elevada entre ambos índices de edificabilidad ($r = 0,81$), factor a considerar en la interpretación del modelo lineal.




Fig. 4: Matriz de correlación de las variables numéricas.

El análisis de outliers mediante el criterio del rango intercuartílico identifica un 11,22% de valores atípicos en el precio y un 10,39% en la superficie del terreno. Como se argumenta en la sección 4, estos valores corresponden a fenómenos genuinos del mercado y no a errores de registro.

3.2 Regresión sobre el precio de transacción

La Tabla 1 resume el desempeño de los tres modelos de regresión sobre el conjunto de prueba, reportando las métricas tanto en la escala logarítmica de entrenamiento como en yenes.

Modelo	R^2 (log)	R^2 (¥)	RMSE (¥)	MAE (¥)	MAPE
Regresión Lineal	0,724	0,100	690.425.179	47.182.148	164,3%
Random Forest	0,705	0,077	699.123.745	43.225.680	195,9%
XGBoost	0,848	0,267	622.950.151	29.490.866	140,1%

Tabla 1. Desempeño de los modelos de regresión sobre el conjunto de prueba.

XGBoost domina en todas las métricas evaluadas. Su superioridad frente a la regresión lineal (0,848 contra 0,724 en R^2 logarítmico) confirma la presencia de relaciones no lineales e interacciones entre ubicación, superficie y antigüedad que el modelo lineal no captura. La validación cruzada de cinco particiones confirma la estabilidad de este ranking: $R^2(\log) = 0,728 \pm 0,003$ para la regresión lineal, $0,707 \pm 0,003$ para Random Forest y $0,850 \pm 0,002$ para XGBoost, sin señales de sobreajuste severo en ningún caso.




Fig. 5: Comparación de métricas entre los tres modelos de regresión, sobre el conjunto de prueba.

La Fig. 6 desagrega el R^2 y el RMSE por partición train/test para cada modelo. La brecha train-test es moderada en los tres casos, lo que descarta un sobreajuste severo: el modelo con mayor separación entre ambas particiones sigue siendo XGBoost, pero es también el que conserva el mejor desempeño en test, señal de que la complejidad adicional se traduce en capacidad predictiva real y no solo en memorización del conjunto de entrenamiento.




Fig. 6: R^2 y RMSE en train vs. test para los tres modelos de regresión.

La Fig. 7 compara, para cada modelo, el precio predicho contra el precio real en escala logarítmica. La nube de puntos de XGBoost se ajusta visiblemente mejor a la diagonal identidad que la de Regresión Lineal y Random Forest, particularmente en el tramo medio de la distribución ($¥10^7$ – $¥10^9$), aunque los tres modelos muestran mayor dispersión en los extremos: operaciones de muy bajo valor y transacciones corporativas por encima de $¥10^{10}$.




Fig. 7: Precio predicho vs. precio real (escala log) para los tres modelos de regresión.

El análisis de residuos del mejor modelo, presentado en la Fig. 8, arroja una media de 0,0010 —prácticamente nula, como corresponde a un estimador insesgado— y un desvío de 0,3693 en escala logarítmica. Este último valor se utilizó posteriormente para construir los intervalos de confianza que muestra la aplicación desplegada. El QQ-plot revela colas más pesadas que una distribución normal, especialmente en el extremo inferior, coherente con la presencia de operaciones cuyo precio real es sustancialmente más bajo que lo que sus atributos físicos sugerirían.




Fig. 8: Análisis de residuos del modelo XGBoost: dispersión, distribución y gráfico cuantil-cuantil.

El análisis de importancia de variables, mostrado en la Fig. 9, sitúa a la superficie construida entre los predictores principales, acompañada por múltiples indicadores de ward —Setagaya, Meguro, Akiruno, Oume, Sugunami, Hachioji y Katsushika aparecen entre las quince variables más influyentes—, lo que respalda empíricamente la decisión de incorporar la dimensión geográfica. La variable de zonificación City planning_Non-Div encabeza el ranking, reforzando el hallazgo de la sección 3.1 sobre el rol indirecto de la accesibilidad a través de la normativa urbana.




Fig. 9: Quince variables más importantes del modelo XGBoost de regresión.

La curva de aprendizaje de la Fig. 10 muestra que, a medida que crece el tamaño del conjunto de entrenamiento, el R^2 de entrenamiento desciende de 0,91 a aproximadamente 0,87 mientras que el de validación cruzada asciende de 0,834 a 0,850, cerrando gradualmente la brecha entre ambas curvas. Este patrón es propio de un modelo con capacidad suficiente que se beneficia de más datos, sin indicios de que el desempeño haya alcanzado una meseta: es esperable que incorporar transacciones adicionales del MLIT siga mejorando el ajuste.




Fig. 10: Curva de aprendizaje del modelo XGBoost (R^2 de entrenamiento vs. validación cruzada).

3.3 Clasificación del sistema constructivo

La distribución del objetivo evidencia un desbalance severo, ilustrado en la Fig. 11: la madera (W) representa el 80,79% de los 224.622 edificios, seguida por acero (S, 7,50%), hormigón armado (RC, 7,45%), la categoría residual «Otros» (3,03%) y acero-hormigón (SRC, 1,23%). La relación entre la clase mayoritaria y la minoritaria alcanza 65,6 a 1. Un clasificador trivial que predijera siempre la clase mayoritaria obtendría una exactitud de 80,8% con un F1 macro de apenas 0,179, brecha que motiva priorizar el F1 macro como métrica de referencia.




Fig. 11: Distribución de clases del objetivo, en escala logarítmica.

La Tabla 2 resume el desempeño de los cinco clasificadores evaluados, agrupados en la Sección B (individuales) y la Sección D.2 (ensambles). El ROC-AUC one-vs-rest se calculó para los tres modelos de la Sección B; para los ensambles de la Sección D.2 no se dispone de este valor, ya que se incorporaron al análisis en una etapa posterior del pipeline experimental (indicado como N/D).

Modelo	F1 macro	F1 ponderado	Exactitud	Kappa	ROC-AUC
Regresión Logística	0,492	0,778	0,725	0,408	0,903
Árbol de Decisión	0,479	0,762	0,703	0,395	0,891
Naive Bayes	0,121	0,258	0,175	0,038	0,579
Random Forest	0,554	0,812	0,772	0,485	N/D
XGBoost	0,568	0,876	0,892	0,636	N/D

Tabla 2. Desempeño de los cinco modelos de clasificación sobre el conjunto de prueba.

XGBoost alcanza el mejor F1 macro (0,568) y la mejor exactitud (89,2%), pero esa exactitud por sí sola sería engañosa: un clasificador trivial que prediga siempre la clase mayoritaria obtendría 80,8% sin detectar ningún otro sistema constructivo. El desempeño desagregado por clase confirma la utilidad del F1 macro: el recall sobre la madera alcanza 0,987 para XGBoost, mientras que sobre la categoría «Otros» se reduce a 0,048 y sobre SRC a 0,454.

Las matrices de confusión de la Fig. 12, normalizadas por fila, corresponden a los tres clasificadores de la Sección B y permiten leer directamente el recall de cada clase. Revelan un fenómeno interesante: los modelos con menor F1

macro global no son necesariamente los que peor detectan las clases raras. La Regresión Logística y el Árbol de Decisión alcanzan un recall de 0,63 y 0,69 sobre «Otros» respectivamente, y de 0,70 y 0,64 sobre SRC, cifras notablemente mejores que las que exhibe XGBoost sobre esas mismas clases minoritarias (0,048 y 0,454). Como se anticipaba en la formulación del problema, la confusión entre RC y SRC es apreciable en los tres modelos, resultado esperable dado que ambos sistemas comparten características constructivas y perfiles de uso similares.




Fig. 12: Matrices de confusión normalizadas por fila — clasificadores de la Sección B. La diagonal representa el recall de cada clase.




Fig. 13: F1 macro en test y comparación train vs. test — clasificadores de la Sección B.

La incorporación de los dos ensambles a la Sección D.2 permite aislar el efecto de cada estrategia. Random Forest comparte el mismo modelo base que el Árbol de Decisión de la Sección B, de modo que la diferencia entre ambos —F1 macro de 0,554 contra 0,479— mide exclusivamente el aporte del bagging: una mejora de +0,075. Comparando el mejor clasificador individual (Regresión Logística, F1 macro = 0,492) contra el mejor ensamble (XGBoost, F1 macro = 0,568), la ganancia total asciende a +0,076. Un ajuste de hiperparámetros de Random Forest mediante RandomizedSearchCV (búsqueda acotada por costo computacional) obtuvo F1 macro = 0,540 en test, ligeramente por debajo del Random Forest con configuración fija entrenado sobre el conjunto completo (0,554), evidencia de que en este caso el volumen de datos de entrenamiento pesó más que la optimización fina de hiperparámetros.

3.4 Análisis no supervisado

Se aplicó agrupamiento por k-medias (MiniBatchKMeans) con un número de clusters igual al número de clases, sobre la totalidad de las features que reciben los clasificadores —incluyendo precio, ward y la geografía codificada—. La coincidencia entre los clusters resultantes y las clases reales de estructura, medida mediante el índice de Rand ajustado, fue de 0,211.

Este valor indica una correspondencia parcial: sensiblemente por encima del azar ($ARI = 0$), pero lejos de una reconstrucción fiel de las cinco clases. La Fig. 14 proyecta ambas particiones sobre las dos primeras componentes principales del mismo espacio de features, que explican en conjunto un 25,1% de la varianza total (17,0% la primera, 8,1% la segunda) —proporción relativamente baja, coherente con un espacio de alta dimensionalidad dominado por las 160 columnas resultantes de la codificación geográfica.




Fig. 14: Proyección PCA del espacio de features utilizado por los clasificadores, coloreada por estructura real (izquierda) y por cluster de MiniBatchKMeans (derecha).

Visualmente, la clase mayoritaria (madera, W) ocupa una región compacta y densa cerca del origen, mientras que RC, S, SRC y Otros se dispersan hacia valores más altos de la primera componente, sin formar agrupamientos claramente separables entre sí. Esto es coherente con la lectura de la sección 3.3: los sistemas de hormigón y acero comparten un perfil de uso y de superficie que dificulta tanto su separación supervisada (confusión RC ↔ SRC) como su emergencia como clusters naturales.

3.5 Aplicación desplegada

La aplicación se encuentra accesible públicamente y permite a un usuario sin conocimientos de programación obtener estimaciones de ambos modelos en tiempo real. El formulario cubre la totalidad de las variables que esperan los pipelines serializados, organizadas en agrupamientos temáticos (ubicación, dimensiones, parcela y entorno, uso del inmueble).

Como contexto informativo, la pestaña de estimación de precio presenta un intervalo de confianza aproximado construido a partir del desvío de los residuos, además del precio por metro cuadrado equivalente; la pestaña de clasificación muestra la distribución completa de probabilidades por clase. Una tercera pestaña documenta las métricas de ambos modelos y sus limitaciones.

4. Discusión

Los resultados obtenidos confirman que los métodos de ensamble basados en árboles superan a los modelos lineales en datos inmobiliarios tabulares, en línea con la literatura previa [2], [3]. La mejora de XGBoost sobre la regresión lineal y sobre la regresión logística es consistente y se sostiene en todas las métricas evaluadas, tanto en regresión como en clasificación.

4.1 Sobre la brecha entre escalas de evaluación

Merece discusión específica la diferencia entre el R^2 calculado en escala logarítmica (0,848) y el calculado en yenes (0,267). Ambos describen el mismo modelo: la brecha obedece a que la transformación inversa amplifica exponencialmente los errores en la cola superior de la distribución. Un error de 0,37 en escala logarítmica —el desvío observado de los residuos— se traduce en miles de millones de yenes cuando se aplica sobre una operación de ¥170.000 millones.

La consecuencia práctica es relevante: el R^2 logarítmico constituye la comparación justa entre modelos, puesto que es la escala en que estos optimizan, pero el R^2 en yenes informa sobre la utilidad real de las estimaciones en valores absolutos. Reportar únicamente el primero habría transmitido una impresión excesivamente favorable del desempeño alcanzado.

4.2 Qué revela el análisis no supervisado

El ARI de 0,211 obtenido sobre el espacio completo de features indica que la agrupación natural por ubicación, tamaño, antigüedad y precio captura una fracción moderada, pero no despreciable, de la estructura constructiva real. La lectura más plausible es que el material de un edificio depende de factores que las variables disponibles capturan solo de manera parcial —normativa antisísmica vigente al momento de la construcción, época, decisión del desarrollador— y que, al mismo tiempo, comparte cierta asociación con variables sí disponibles: los edificios de madera tienden a ser residenciales, más pequeños y de menor antigüedad relativa, rasgos que el espacio de features sí codifica.

Esa correspondencia parcial es coherente con el techo observado en el desempeño de los clasificadores supervisados: si la estructura constructiva emergiera con nitidez de los atributos físicos y geográficos disponibles, cabría esperar tanto un ARI más alto en el análisis no supervisado como un F1 macro más cercano a 1 en la clasificación. Ninguno de los dos ocurre, lo que sugiere que una fracción del poder predictivo del sistema constructivo reside en información no capturada por el registro del MLIT.

Una limitación metodológica de este análisis es que k-medias minimiza distancias euclídeas y, tras la estandarización, cada variable contribuye en proporción a su varianza relativa. El precio de transacción, con una asimetría de 150,4, y las más de cien columnas dispersas provenientes de la codificación geográfica, pueden dominar la geometría del espacio y diluir la contribución relativa de los atributos puramente constructivos (superficie, ratio construido, antigüedad). Una línea de trabajo futuro natural es repetir este análisis restringiendo las features a los atributos físicos del inmueble, para aislar si esa restricción mejora o empeora la correspondencia con las clases reales.

4.3 Etapa más desafiante y decisiones a revisar

Considerando el recorrido completo del proyecto, la etapa más desafiante no fue el modelado sino la preparación de los datos. Tres de los cinco problemas de calidad identificados —el artefacto de codificación, la distancia textual y el objetivo multi-etiqueta— habrían pasado inadvertidos bajo un procesamiento superficial, y cada uno tenía potencial para invalidar los resultados. El caso del objetivo multi-etiqueta es ilustrativo: sin normalización, el clasificador habría entrenado sobre 26 categorías, varias con un puñado de ejemplos, y las métricas macro se habrían vuelto ruido estadístico.

Con el conocimiento adquirido, tres decisiones se tomarían de forma diferente. En primer lugar, el alcance geográfico: el proyecto se planteó inicialmente sobre un único distrito y se amplió a la prefectura completa recién avanzado el desarrollo, lo que obligó a rehacer buena parte del análisis exploratorio. Los resultados de la sección 3.1 muestran que la comparación entre distritos es precisamente el hallazgo más valioso, de modo que el alcance amplio debió adoptarse desde el inicio.

En segundo lugar, el tratamiento de la cardinalidad geográfica: el criterio de umbral porcentual resultó inadecuado para el tamaño del conjunto y debió reemplazarse por un criterio top-N. En tercer lugar, el costo computacional se subestimó sistemáticamente: la búsqueda de hiperparámetros sobre el conjunto completo resultó inviable tanto en el regresor Random Forest como en el clasificador del mismo nombre, y debió acotarse mediante muestreo (50.000 filas para regresión), con el resultado —discutido en 3.2 y 3.3— de que el modelo ajustado sobre la muestra terminó rindiendo levemente peor en test que el modelo con hiperparámetros fijos entrenado sobre el conjunto completo. Esta observación habría convenido anticiparla desde el diseño experimental, priorizando volumen de datos de entrenamiento sobre exhaustividad de la búsqueda cuando ambos compiten por presupuesto computacional.

4.4 Utilidad real de la solución desplegada

Respecto de la utilidad práctica para un usuario final, corresponde ser cauto. El modelo de regresión resulta adecuado para estimar el orden de magnitud de una operación típica, pero su MAPE del 140% lo inhabilita como

herramienta de tasación profesional. Un error relativo de esa magnitud significa que la estimación puede desviarse en más del doble del valor real, especialmente en el segmento de operaciones grandes.

Esta limitación motivó una decisión de diseño central en la aplicación: en lugar de presentar una estimación puntual —que induciría una falsa sensación de precisión—, la interfaz muestra un intervalo construido a partir del desvío de los residuos en escala logarítmica, necesariamente asimétrico al expresarse en yenes, y emite una advertencia explícita cuando la estimación cae en la cola alta de la distribución o cuando la superficie ingresada corresponde al rango censurado. De modo análogo, la pestaña de clasificación señala cuando la predicción corresponde a una clase minoritaria sobre la que el modelo exhibe bajo recall.

Otras limitaciones prácticas son inherentes a los datos de entrada requeridos. La aplicación exige que el usuario conozca atributos como el building coverage ratio o el floor area ratio, información disponible en la documentación catastral pero no necesariamente al alcance de un particular. Una mitigación posible sería precargar esos valores a partir del ward y la zonificación seleccionados, utilizando las medianas históricas del conjunto de datos.

4.5 Requisitos para un entorno profesional y riesgos éticos

Llevar esta solución a un entorno profesional real exigiría varios componentes ausentes en la implementación actual. En primer término, monitoreo del modelo: registro de las predicciones realizadas y de las características de entrada, para detectar deriva (model drift) mediante la comparación periódica entre la distribución de los datos de producción y la de entrenamiento. El mercado inmobiliario es sensible a ciclos macroeconómicos, de modo que un modelo entrenado sobre el período 2005–2025 perderá vigencia progresivamente.

En segundo término, reentrenamiento periódico automatizado, dado que el MLIT actualiza su registro trimestralmente. En tercer término, escalabilidad: la arquitectura actual carga los modelos en memoria en un único proceso, esquema adecuado para uso demostrativo pero insuficiente ante carga concurrente significativa. Finalmente, seguridad: validación estricta del lado del servidor y limitación de tasa de peticiones.

Los riesgos éticos merecen consideración explícita antes de cualquier despliegue a gran escala. Los datos son autoreportados por las partes intervinientes, lo que admite subreporte sistemático. La cobertura se restringe a Tokio, de modo que el modelo no generaliza a otras prefecturas. Y el registro omite atributos determinantes del valor —calidad constructiva, estado de conservación, condiciones particulares de cada negociación— que ningún algoritmo puede inferir de las variables disponibles.

Más delicado aún: un sistema de valuación desplegado a escala podría inducir profecías autocumplidas. Si los agentes del mercado adoptan las estimaciones del modelo como referencia, los precios convergerían hacia sus predicciones, consolidando los patrones históricos —incluidas eventuales desigualdades territoriales— en lugar de reflejar el valor real. El modelo aprende que ciertos distritos son más baratos, y su uso masivo contribuiría a que lo sigan siendo.

5. Conclusiones

Este trabajo desarrolló un pipeline analítico completo sobre 343.995 transacciones inmobiliarias de la Prefectura de Tokio, abarcando desde la preparación de datos hasta el despliegue en producción de dos modelos predictivos.

Respecto de los objetivos planteados, se identificaron y resolvieron cinco problemas de calidad no triviales del registro del MLIT, documentando cada decisión metodológica (OE1). Se compararon tres algoritmos de regresión y cinco de clasificación, obteniendo XGBoost el mejor desempeño en ambas tareas: R^2 logarítmico de 0,848 en regresión y F1 macro de 0,568 en clasificación multiclase bajo un desbalance de 65,6 a 1, con una ganancia de +0,076 en F1 macro frente al mejor clasificador individual (OE2). Ambos modelos se desplegaron en una aplicación web pública que comunica explícitamente la incertidumbre de sus estimaciones (OE3).

Entre los hallazgos sustantivos, la comparación entre distritos reveló una variación de hasta cuatro veces en el precio por metro cuadrado, con un ordenamiento por volumen de operaciones prácticamente inverso al de precio. La distancia a la estación mostró una asociación con el precio mucho más débil de lo esperado, operando aparentemente por vía indirecta a través de la zonificación urbana. Al comparar los dos ensambles con sus respectivos modelos base, se pudo aislar el efecto del bagging (+0,075 en F1 macro, comparando Árbol de Decisión contra Random Forest) del efecto conjunto de boosting y ensamblado que exhibe XGBoost.

El análisis no supervisado mostró una correspondencia parcial entre los clusters de k-medias y las clases reales de estructura constructiva (ARI = 0,211): la ubicación, el tamaño y el precio capturan una fracción moderada de la señal constructiva, coherente con el techo de desempeño observado en los clasificadores supervisados.

La implicación práctica principal es que la solución desplegada resulta útil como herramienta orientativa y demostrativa, pero no como instrumento de tasación profesional. Reconocer esa distinción, y comunicarla en la propia interfaz, constituye a nuestro juicio una parte tan importante del trabajo como el desempeño de los modelos.

Como líneas de trabajo futuro se identifican: la incorporación de variables geoespaciales explícitas (coordenadas, distancia al centro urbano), que podrían capturar el efecto de ubicación con mayor granularidad que el ward; la evaluación de técnicas de sobremuestreo (SMOTE) para las clases minoritarias del problema de clasificación, contempladas pero no ejecutadas en este trabajo; la repetición del análisis de clustering restringiendo las variables a los atributos físicos del inmueble, para evaluar si aislarlas del precio y la geografía mejora la correspondencia con las clases reales; la construcción de intervalos de predicción mediante regresión cuantílica, más rigurosa que la aproximación por desvío de residuos empleada aquí; y la exploración de un modelado segmentado que trate por separado el mercado residencial y el corporativo, cuya mezcla explica buena parte del error observado en escala absoluta.

Referencias

- [1] Ministry of Land, Infrastructure, Transport and Tourism of Japan, “Real Estate Transaction Price Information”, 2025. [Online]. Available: https://www.land.mlit.go.jp/webland_english/servlet/MainServlet
- [2] T. Chen y C. Guestrin, “XGBoost: A scalable tree boosting system”, en Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining, San Francisco, CA, EE.UU., 2016, pp. 785–794.
- [3] L. Breiman, “Random forests”, Machine Learning, vol. 45, no. 1, pp. 5–32, Oct. 2001.
- [4] T. Hastie, R. Tibshirani y J. Friedman, The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2a ed. Nueva York, NY, EE.UU.: Springer, 2009.
- [5] H. He y E. A. Garcia, “Learning from imbalanced data”, IEEE Trans. Knowledge and Data Engineering, vol. 21, no. 9, pp. 1263–1284, Sep. 2009.
- [6] F. Pedregosa et al., “Scikit-learn: Machine learning in Python”, Journal of Machine Learning Research, vol. 12, pp. 2825–2830, Oct. 2011.
- [7] Streamlit Inc., “Streamlit documentation”, 2025. [Online]. Available: <https://docs.streamlit.io>